

Komplexitet & Korrekthet

Klassificering och jämförelse av körtider

- Vi har två algoritmer
 - $a_1(n)$ med körtid $n^2 + 7n + 128$
 - $a_2(n)$ med körtid $n^2 + 12n + 10$
- Körtiderna är olika men domineras av n^2 -termen för stora n
- Ekvivalent effektivitet iom båda körtiderna är kvadratiska uttryck av indatastorleken
- Det är ofta svårt att hitta ett exakt uttryck för körtiden
- Vi vill istället generalisera detta

Hur kan vi enkelt beskriva algoritmernas körtid på ett sätt som fångar denna typ av ekvivalens?

- Ordo-notation! (eng. Big-O notation)
- För både a_1 och a_2 från föregående slide så har vi $a_1(n) \in O(n^2)$ och $a_2(n) \in O(n^2)$
- Skrivs ibland slarvigt med likhetstecken, $f(n) = O(n^2)$

Definition:

Uttrycket $f(n) \in O(g(n))$ säger att

" $f(n)$ är begränsad överifrån av $g(n)$ (gårer någon konstant) för stora n "

Formellt:

$$f(n) \in O(g(n))$$

$$\iff$$

det finns några $n_0 \geq 0$ och $c > 0$ så att $f(n) < c \cdot g(n)$ för alla $n \geq n_0$

Beräkning med ordo-notation; låt säga att vi har

$$f(n) = 20 + 15n + 10n^2$$

Om $n > 1$ så

$$f(n) < 20n^2 + 15n^2 + 10n^2 = 45n^2$$

Låt då $n_0 = 2, c = 45$:

$$f(n) < 45 \cdot n^2, n \geq 2 \iff f(n) \in O(n^2)$$

- Big-O ger bara en övre gräns, så om $f(x) \in O(n^2)$ så har vi även $f(x) \in O(n^3)$
- dvs $O(n^2) \subset O(n^3)$
- För att ge en undre gräns använder vi Ω -notation:

$$f(n) \in \Omega(g(n)) \iff f(n) \text{ är begränsad underifrån av } g(n) \text{ för stora } n$$

- Vi kan kombinera dessa med Θ för att få en mer exakt beskrivning av körtiden:

$$f(n) \in \Theta(g(n)) \iff f(n) \text{ är begränsad överifrån och underifrån av } g(n) \text{ för stora } n$$

- Beskriver körtiden "exakt", $\Theta(n^2)$ är skilt från $\Theta(n^3)$

- $\{\text{Körtid för } A\} \in O(f(n)) \iff A \text{ har } \textit{tidskomplexitet } O(f(n))$
- På samma sätt kan vi tala om *minneskomplexitet*

- Vi talar oftast om tidskomplexiteten i det *värsta fallet*, men det finns även *bästa fall* och *genomsnittlig*
- Ibland är alla dessa samma, ibland inte
- Ett extremt exempel: bogosort
 - T_{best} :
 - T_{worst} :
 - T_{avg} :

- Vi talar oftast om tidskomplexiteten i det *värsta fallet*, men det finns även *bästa fall* och *genomsnittlig*
- Ibland är alla dessa samma, ibland inte
- Ett extremt exempel: bogosort
 - $T_{\text{best}}(n) : O(1)$
 - $T_{\text{worst}}(n) :$
 - $T_{\text{avg}}(n) :$

- Vi talar oftast om tidskomplexiteten i det *värsta fallet*, men det finns även *bästa fall* och *genomsnittlig*
- Ibland är alla dessa samma, ibland inte
- Ett extremt exempel: bogosort
 - $T_{\text{best}}(n) : O(1)$
 - $T_{\text{worst}}(n) : O(\infty)$
 - $T_{\text{avg}}(n) :$

- Vi talar oftast om tidskomplexiteten i det *värsta fallet*, men det finns även *bästa fall* och *genomsnittlig*
- Ibland är alla dessa samma, ibland inte
- Ett extremt exempel: bogosort
 - $T_{\text{best}}(n) : O(1)$
 - $T_{\text{worst}}(n) : O(\infty)$
 - $T_{\text{avg}}(n) : O(n \cdot n!)$

findMax(L, n)

$m \leftarrow -\infty$

for $i \leftarrow 1$ **to** n **do**

if $L_i > m$ **then**

$m \leftarrow L_i$

return m

- Vi gör ett konstant antal operationer utanför slingan (k)
- Vi gör ett konstant antal operationer för varje iteration (m)
- Slingan körs n gånger
- Vi gör $k + mn$ operationer
- Tidskomplexiteten blir $O(k + mn) = \underline{O(n)}$
- Hur hade det sett ut om vi hade en nästlad slinga?

Mästarsatsen

- Antag att vi har en rekursiv algoritm
- Algoritmen anropar sig själv a gånger med indata minskad med en faktor b
- Algoritmen gör ytterligare operationer som har körtid $f(n) = O(n^d)$
- Då är körtiden för algoritmen

$$T(n) = aT(n/b) + f(n)$$

$$T(n) = aT(n/b) + f(n), \quad f(n) = O(n^d)$$

$$T(n) = \begin{cases} \Theta(n^d) & \text{om } a < b^d \\ \Theta(n^d \log n) & \text{om } a = b^d \\ \Theta(n^{\log_b a}) & \text{om } a > b^d \end{cases}$$

Merge-sort

- Algoritm för att sortera en lista
- Sorterar delar av input och sammanslagar dessa (därför *merge*)
- Är en typ av *divide-and-conquer*-algoritm

Exempel

2	7	1	4	8	5	6	3
---	---	---	---	---	---	---	---

Dela indataan

2	7	1	4
---	---	---	---

8	5	6	3
---	---	---	---

Sortera varje dellista

1	2	4	7
---	---	---	---

3	5	6	8
---	---	---	---

Kombinera resultatet

2	4	7
---	---	---

3	5	6	8
---	---	---	---

1

Kombinera resultatet

4	7
---	---

3	5	6	8
---	---	---	---

1	2
---	---

Kombinera resultatet

4	7
---	---

5	6	8
---	---	---

1	2	3
---	---	---

Kombinera resultatet

7

5 6 8

1 2 3 4

Kombinera resultatet

7

6	8
---	---

1	2	3	4	5
---	---	---	---	---

Kombinera resultatet

7

8

1	2	3	4	5	6
---	---	---	---	---	---

Kombinera resultatet

8

1	2	3	4	5	6	7
---	---	---	---	---	---	---

Klart!

1	2	3	4	5	6	7	8
---	---	---	---	---	---	---	---

- Vi gör två rekursiva anrop $\Rightarrow a = 2$
- Vi delar indata i två $\Rightarrow b = 2$
- Vi sammanslagar resultaten i $O(n)$ $\Rightarrow d = 1$

$$T(n) = \begin{cases} \Theta(n^d) & \text{om } a < b^d \\ \Theta(n^d \log n) & \text{om } a = b^d \\ \Theta(n^{\log_b a}) & \text{om } a > b^d \end{cases}$$

$$a = b^d \Rightarrow T(n) = O(n^d \log n) = \underline{O(n \log n)}$$

Komplexitetsklasser

- En gruppering av problem med liknande tids- eller minneskomplexitet
- Det handlar om *beslutsproblem* (ja/nej)
- Exempel:
 - **P** = problem som kan *lösas* i polynomisk tid ($O(n^k)$)
 - **NP** = problem som kan *verifieras* i polynomisk tid

- Exempel på NP-problem:

Kan en graf $G = (V, E)$ nodfärgas med k färger?

- Det finns ingen känd algoritm i P, men vi kan verifiera en godtycklig lösning i polynomisk tid
- Indatan kallas för *instans* och lösningen kallas för *certifikat*
- Vad blir dessa i detta fall?
- Hur kan vi konstruera en *verifierare* (algoritmen som verifierar lösningen)?
- Gäller $P \subseteq NP$?

- **NP-svårt problem** = problem som är minst lika svårt som ett problem i NP
- Men hur vet vi om ett problem är "svårare" än ett annat?

- Svar: vi använder *reduktioner*
- En reduktion är en algoritm som omvandlar en instans för ett problem A till en instans för ett problem B . Om algoritmen är polynomisk säger vi att

$$A \leq_p B$$

- Exempel: Hamiltoncykel \leq_p Hamiltonstig i grafer
- Ett problem B är **NP-svårt** om $A \leq_p B$ för varje problem A i NP, det vill säga, varje NP-problem kan reduceras till B .

- Ett problem är **NP-fullständigt** om det ligger i NP och är NP-svårt
- Exempel på NP-fullständiga problem:
 - *Graffärgning*: kan noder färgas med k färger så att grannar inte har samma färg?
 - *Satisfierbarhet*: t.ex. finns x_1, x_2, x_3 så att $(x_1 \wedge x_2) \vee \overline{x_3}$?
 - *Hamiltonstig*: finns en stig i en graf som går genom varje nod exakt en gång?
- Alla NP-fullständiga problem kan reduceras till varandra (varför?)

P=N P?

- Vi vet att $P \subseteq NP$
- Ingen vet om $P = NP$
- De flesta tror dock att $P \neq NP$

- Varför spelar det någon roll?
- Problem i P representerar problem som (i allmänhet) kan lösas i rimlig tid i verkligheten
- Om vi t.ex. hittar en polynomisk algoritm som löser ett NP-fullständigt problem, vet vi att $P = NP$, och vi kan lösa alla problem i NP i rimlig tid
- Primtalsfaktorisering ligger i NP, och RSA bygger på antagandet att primtalsfaktorisering tar lång tid

Korrekthet

Hur kan man visa att en algoritm gör det den ska göra?

- **findMax** är en funktion som hittar det största värdet i en lista med heltal
- Hur visar vi att den är korrekt?

findMax(L, n)

$m \leftarrow -\infty$

$i \leftarrow 1$

while $i \leq n$ **do**

if $L_i > m$ **then**

$m \leftarrow L_i$

$i \leftarrow i + 1$

return m

- Svar: vi använder en *slinginvariant*.
- Ett påstående som är sant i början och i slutet av varje iteration.
- Om det är sant innan slingan vet vi att det är sant efter slingan.

- Vad skulle vara en bra slinginvariant i den här koden?

findMax(L, n)

$m \leftarrow -\infty$

$i \leftarrow 1$

while $i \leq n$ **do**

if $L_i > m$ **then**

$m \leftarrow L_i$

$i \leftarrow i + 1$

return m

findMax(L, n)

pre L är en lista med heltal av längd n .

post m är det största värdet i L .

$m \leftarrow -\infty$

$i \leftarrow 1$

while $i \leq n$ **do**

inv $m \geq L_k$ för $1 \leq k < i$

if $L_i > m$ **then**

| $m \leftarrow L_i$

$i \leftarrow i + 1$

return m

- Bevismetod som liknar dominoeffekten
- Vi vill bevisa ett påstående $P(n) \forall n \geq m$
- Består av tre delar:
 - *Induktionsbas:* Vi visar att $P(m)$ gäller
 - *Induktionsantagande:* Vi antar att $P(k)$ för något k
 - *Induktionssteg:* Vi visar att $P(k) \Rightarrow P(k + 1)$
- Då gäller $P(n) \forall n \geq m$

Vi vill visa att

$$\sum_{k=0}^n k = \frac{n(n+1)}{2} \quad \forall n \geq 0.$$

Steg 1: *Induktionsbas*

$$\sum_{k=0}^0 k = 0 = \frac{0(0+1)}{2}.$$

Steg 2: *Induktionsantagande*

$$\sum_{k=0}^m k = \frac{m(m+1)}{2} \text{ för något } m.$$

Steg 3: Induktionssteg

$$\begin{aligned} \sum_{k=0}^{m+1} k &= m + 1 + \sum_{k=0}^m k = m + 1 + \overbrace{\frac{m(m+1)}{2}}^{\text{Induktionsantagande}} \\ &= \frac{2m + 2 + m^2 + m}{2} = \frac{m^2 + 3m + 2}{2} = \frac{(m+1)(m+2)}{2} \end{aligned}$$

Enligt induktionsprincipen gäller påståendet för alla $n \geq 0$.

- Induktion kan även användas för att bevisa korrekthet för rekursiva funktioner.

```
findMaxRecursive( $L$ ,  $n$ )
  if  $n = 1$  then
    | return  $L_1$ 
     $M \leftarrow \text{findMaxRecursive}(L, n - 1)$ 
    if  $L_n > M$  then
      | return  $L_n$ 
    else
      | return  $M$ 
```

- Vad är påståendet vi vill bevisa?
- Vad är induktionsbas, -antagande och -steg?

```
findMaxRecursive( $L, n$ )  
    if  $n = 1$  then  
        | return  $L_1$   
         $M \leftarrow \text{findMaxRecursive}(L, n - 1)$   
        if  $L_n > M$  then  
            | return  $L_n$   
        else  
            | return  $M$ 
```

Vi vill visa att

$$\text{findMaxRecursive}(L, n) = \max_{i \leq n} \{L_i\} \quad \forall n \geq 1$$

Varför $n \geq 1$?

Induktionsbas:

```
if  $n = 1$  then
| return  $L_1$ 
```

$$\text{findMaxRecursive}(L, 1) = L_1 = \max_{i \leq 1} \{L_i\}$$

Induktionsantagande:

$$\text{findMaxRecursive}(L, k) = \max_{i \leq k} \{L_i\} \text{ för något } k$$

Induktionssteg:

$M \leftarrow \text{findMaxRecursive}(L, n - 1)$

if $L_n > M$ **then**

| **return** L_n

else

| **return** M

findMaxRecursive($L, k + 1$)

= $\max\{L_{k+1}, \text{findMaxRecursive}(L, k)\}$

$$= \max \left\{ L_{k+1}, \underbrace{\max_{i \leq k} \{L_i\}}_{\text{Induktionsantagande}} \right\}$$

$$= \max_{i \leq k+1} \{L_i\}$$